Lab 02 - Python - Trevisan - 277200

Carregamento dos Datasets

```
library(Replicate)
```

```
reticulate::py_require("polars")
```

```
import polars as pl
```

```
basics = pl.scan_csv(
    "title.basics0.tsv.gz",
    separator="\t",
    null_values="\\N",
    infer_schema_length=10000
)

ratings = pl.scan_csv(
    "title.ratings.tsv.gz",
    separator="\t",
    null_values="\\N"
).with_columns(
    pl.col("averageRating").cast(pl.Float64),
    pl.col("numVotes").cast(pl.Int64)
)

principals = pl.scan_csv(
    "title.principals0.tsv.gz",
    separator="\t",
    null_values="\\N"
)
```

1. Quais são os 5 filmes com as maiores notas (averageRating)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```
q1 = (
    ratings
    .join(basics.filter(pl.col("titleType") == "movie"), on="tconst", how="inner")
    .sort(by=["averageRating", "numVotes"], descending=[True, True])
    .head(5)
    .select(["tconst", "primaryTitle", "averageRating", "numVotes", "startYear"])
).collect()

print(q1)
```

```
shape: (5, 5)

 tconst      primaryTitle               averageRating  numVotes  startYear
 ---         ---                        ---            ---       ---
 str         str                        f64            i64       i64

 tt33075815  Kaveri                     10.0           1023      2024
 tt27815015  Kurukku                    10.0           451       2024
 tt28450376  Jedal Dar Omghe 30 Metri   10.0           142       2009
 tt27859713  Sargashte                  10.0           134       2016
 tt33507675  Gorgeous Rascal            10.0           115       2024
```

Solução para desempate: Filtrar os registros para considerar apenas itens do tipo filme,então juntamos as tabelas de avaliações e informações básicas, e ordenamos de forma decrescente tanto pela nota quanto pelo número de votos para o desempate.

2. Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```
q2 = (
    ratings
    .filter(pl.col("averageRating") > 8.0)
    .join(basics.filter(pl.col("titleType") == "movie"), on="tconst", how="inner")
    .with_columns(pl.col("genres").str.split(","))
    .explode("genres")
    .filter(pl.col("genres").is_not_null() & (pl.col("genres") != ""))
```

```
    .group_by("genres")
    .agg(pl.len().alias("frequency"))
    .sort("frequency", descending=True)
    .head(1)
).collect()

print(q2)
```

```
shape: (1, 2)

 genres        frequency
 ---           ---
 str           u32

 Documentary   10564
```

3. Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
movies_high_rating = (
    ratings
    .filter(pl.col("averageRating") > 7.5)
    .join(basics.filter(pl.col("titleType") == "movie"), on="tconst", how="inner")
)

q3 = (
    principals
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .join(movies_high_rating, on="tconst", how="inner")
    .group_by("nconst")
    .agg(pl.len().alias("appearance_count"))
    .sort("appearance_count", descending=True)
    .head(3)
).collect()

print(q3)
```

```
shape: (3, 2)
```

```
nconst      appearance_count
---         ---
str         u32

nm0004660   231
nm0595934   155
nm3183374   124
```

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-14 13:31:58 -03"
```